Tema 2 - laboratorul 3
Probabilități condiționate. Formula lui Bayes

Ex 1: Spațiul de eșantionare:

$\Omega = \{(x,y) \mid x,y \in \{1,2,3,4,5,6\}\}$, $|\Omega| = 6 \cdot 6 = 36$

P.p că zarurile sunt corecte și aruncările sunt independente $\Rightarrow$ rezultatele sunt **echiprobabile**:

$$P(\{(x,y)\}) = \frac{1}{36}$$

$$P(E) = \frac{|E|}{36}$$

Formula probabilității condiționate: $P(A|B) = \frac{P(A \cap B)}{P(B)}$

Notăm evenimentele:

$A = \{X + Y \geq 10\}$

$B = \{X \text{ este par}\}$

$C = \{\text{cel puțin un zar par}\}$

$\Delta = \{X + Y = 8\}$

$E = \{X \text{ par și } Y \text{ par}\}$

Evenimentul A: $A = \{(4,6), (5,5), (6,4), (5,6), (6,5), (6,6)\}$

$|A| = 6 \Rightarrow P(A) = \frac{6}{36} = \frac{1}{6}$

1. $P(A|B)$: suma ≥ 10, știind că primul zar e par

$B = \{X \in \{2,4,6\}\}$ → are 3 valori pt X și 6 pt Y

$|B| = 6 \cdot 3 = 18$ $\quad P(B) = \frac{18}{36} = \frac{1}{2}$

$A \cap B = \{(4,6), (6,4), (6,5), (6,6)\} \Rightarrow P(A \cap B) = \frac{4}{36}$

↳ din A păstrăm doar perechile cu X par

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{\frac{4}{18}}{} = \frac{2}{9} \simeq 0.222$$

2. $P(A|C)$: suma ≥ 10, știind că cel puțin un zar e par

→ îl calculăm prin complementară:

$\bar{C} = \{\text{ambele zaruri impare}\}$, adică $X, Y \in \{1,3,5\} \Rightarrow |\bar{C}| = 3 \cdot 3 = 9$

$$P(C) = 1 - P(\bar{C}) = 1 - \frac{9}{36} = \frac{27}{36} = \frac{3}{4}$$

$$A \cap C = \{(4,6), (6,4), (5,6), (6,5), (6,6)\} \Rightarrow P(A \cap C) = \frac{5}{36}$$

$$P(A|C) = \frac{P(A \cap C)}{P(C)} = \frac{5}{27} \simeq 0.185$$

3. $P(E|\Delta)$: ambele pare, știind că suma e 8

$$\Delta = \{(2,6), (3,5), (4,4), (5,3), (6,2)\} \qquad P(\Delta) = \frac{5}{36}$$

$$E \cap \Delta = \{(2,6), (4,4), (6,2)\} \qquad P(E \cap \Delta) = \frac{3}{36}$$

$$P(E|\Delta) = \frac{P(E \cap \Delta)}{P(\Delta)} = \frac{3}{5} \simeq 0.6$$

4. Sunt A și B independente?

A și B sunt independente $\Leftrightarrow P(A \cap B) = P(A) \cdot P(B)$

$P(A \cap B) = \frac{4}{36} = \frac{1}{9}$ ① $\qquad P(A) \cdot P(B) = \frac{1}{6} \cdot \frac{1}{2} = \frac{1}{12}$ ②

① ≠ ② $\Rightarrow$ A și B NU sunt independente

Interpretare: Dacă afli că primul zar e par, șansa ca suma ≥ 10 crește deoarece printre valorile pare se află 6 $\Rightarrow$ cea mai mare valoare, în timp ce printre cele impare se află 1

Ex 2 Filtrarea mesajelor spam

Evenimentele:

S = mesajul este spam, iar $L = \bar{S}$ = mesajul este legitim

O = mesajul conține cuvântul ofertă

G = mesajul conține cuvântul gratuit

$P(S) = 0.3 \Rightarrow P(L) = 1 - P(S) = 0.7$

„oferta apare 80% din spam" $\Rightarrow P(O|S) = 0.8$

„oferta apare 15% din legitime" $\Rightarrow P(O|L) = 0.15$

$P(G|S) = 0.6$

$P(G|L) = 0.1$

Probabilitatea totală:

$$P(O) = P(O|S)P(S) + P(O|L)P(L)$$

Teorema lui Bayes

$$P(S|O) = \frac{P(O|S)\,P(S)}{P(O)}$$

→ putem să a gândim ca $P(\text{vitar} \mid \text{trecut})$ → dacă s-a întâmplat trecutul cât de probabil e vitarul

$P(\text{trecut} \mid \text{vitar})$ → am văzut vitarul, cât de probabil e să se fi întâmplat trecutul

trecut vitar

1. $$P(S|O) = \frac{P(O|S)\,P(S)}{P(O)}$$

$$P(O) = P(O|S)P(S) + P(O|L)\,P(L) = 0.24 + 0.105 = 0.345$$

$$P(S|O) = \frac{0.8 \cdot 0.3}{0.345} = \frac{16}{23} \simeq 0.69$$

2. $$P(S|O \cap G) = \frac{P(O \cap G|S)\,P(S)}{P(O \cap G)}$$

$$P(O \cap G) = P(O \cap G|S) \cdot P(S) + P(O \cap G|L) \cdot P(L)$$

Considerăm independența condiționată a apariției celor două cuvinte:

$$P(O \cap G|S) = P(O|S) \cdot P(G|S)$$
$$P(O \cap G|L) = P(O|L) \cdot P(G|L)$$

$$P(O \cap G|S) = 0.8 \cdot 0.6 = 0.48$$
$$P(O \cap G|L) = 0.15 \cdot 0.1 = 0.015$$

$$P(O \cap G) = 0.48 \cdot 0.3 + 0.015 \cdot 0.7 = 0.144 + 0.0105 = 0.1545$$

$$P(S|O \cap G) = \frac{0.48 \cdot 0.3}{0.1545} = \frac{0.144}{0.1545} = \frac{96}{103} \simeq 0.932$$

3. De ce independența condiționată poate fi naivă?

Spațiză:

Știind că un mesaj e în spam, faptul că apare "aftă" nu schimbă probabilitatea să apară și "gratuit"

$$P(G|O,S) = P(G|S)$$

Spațiza poate fi naivă pentru că cele două cuvinte apar de obicei împreună. Într-un spam care conține "aftă" e mai probabil

să apară și „gratuit", deci în realitate:

$$P(G|O,S) > P(G|S)$$

Cele două cuvinte aduc în mare parte aceeași informație → dar modelul le tratează ca pe două dovezi separate. → numără de două ori aceleași indicii și obține un posterior prea mare.

4. Regulă de clasificare bazată pe probl. condiționată:

O regulă cu trei zone, care compară probabilitatea posteriorului (e curs după ce citești mesajul) cu priorul (ce credeai înainte, 0.3):

- $P(S|date) \leq 0.3$ → Inbox
  (nu au crescut suspiciunea)
- $0.3 < P(S|date) \leq 0.9$ → De verificat
  (suspect, dar nu suficient de sigur) → lasă omul să decidă
- $P(S|date) > 0.9$ → Spam
  (aproape siguri) /mai multe date

Priorul: pragul de jos → un mesaj este considerat sigur dacă observarea cuvintelor nu a mărit probabilitatea de spam

Posteriorul: pragul de sus → e ridicat deoarece a clasifica greșit un mesaj legitim e mai costisitor decât invers

Ex 3 Paradoxul lui Simpson

Program	Disciplină A	Disciplina B
Programul 1	81 din 90	19 din 20
Programul 2	1 din 10	78 din 80

P = "studentul promovează"

Variabile: - disciplina: A și B
- program: P_1 și P_2

1. O rata de promovare = a probabilitate condiționată
   ↳ câți au promovat, împărțit la câți au dat examenul

Ex: 81 din 90 la disciplina A din programul 1

$$P(P|A,P_1) = \frac{81}{90} = 0.90$$

$$P(P|B,P_1) = \frac{19}{20} = 0.95$$

$$P(P|A,P_2) = \frac{1}{10} = 0.10 \qquad P(P|B,P_2) = \frac{16}{80} = 0.20$$

	A	B
P_1	0.90	0.95
P_2	0.10	0.20

2. Care disciplină are a rată de promovare mai mare?

Programul 1: $0.95 > 0.90$, B are rata mai mare
Programul 2: $0.20 > 0.10$, B are rata mai mare
$\Rightarrow$ B este mai bună în ambele programe

3. Rata globală de promovare pt. ambele discipline

$$P(P|A) = \frac{81+1}{90+10} = \frac{82}{100} = 0.82$$

$$P(P|B) = \frac{19+16}{80+20} = \frac{35}{100} = 0.35$$

$\Rightarrow$ Global A este mai bună, dar B e mai bună în fiecare program → asta e paradoxul

4. De ce ordinea disciplinelor se inversează?

$P \cap A = (P \cap A \cap P_1) \cup (P \cap A \cap P_2)$

$P(P \cap A) \overset{\text{a. m. disj}}{=} P(P \cap A \cap P_1) + P(A \cap P \cap P_2)$

$P(P \cap A \cap P_i) = P(P|A \cap P_i) \cdot P(A \cap P_i)$ → fiecare termen îl scriem cu regula produsului

Împărțim la $P(A)$ și folosim def probabilității cond: $\frac{P(A \cap P_i)}{P(A)} = P(P_i|A)$

Obținem formula probabilității totale:

$$P(P|A) = \underbrace{P(P|A,P_1)}_{\text{rata de promovare}} \cdot \overbrace{P(P_1|A)}^{\text{pondirea programului}} + P(P|A,P_2) \cdot P(P_2|A)$$

Analog pt B:

$$P(P|B) = P(P|B,P_1) \cdot P(P_1|B) + P(P|B,P_2) \cdot P(P_2|B)$$

$P(P_1|A) = \frac{90}{100} = 0.9$ $\quad P(P_2|A) = \frac{10}{100} = 0.1$

$P(P_1|B) = \frac{20}{100} = 0.2$ $\quad P(P_2|B) = \frac{80}{100} = 0.8$

$P(P|A) = 0.90 \cdot 0.9 + 0.10 \cdot 0.1 = 0.81 + 0.01 = 0.82$

$P(P|B) = 0.95 \cdot 0.2 + 0.20 \cdot 0.8 = 0.19 + 0.16 = 0.35$

$\Rightarrow$ Rata globală este o medie ponderată a ratelor pe programe, iar ponderile diferă:

- la A: ponderea e mare (0.9) pe P_1, unde rata e mare 0.98
- la B: ponderea mare (0.8) este pe P_2, unde rata e mică

Dacă ne uităm la fiecare program separat, B are rezultate mai bune decât A.

Dacă adunăm toți studenții la un loc, A pare mai bună.

Asta se întâmplă pentru că la A au dat examen mai ales studenții din Programul 1, unde aproape toți trec. La B au dat mai mulți studenți din Programul 2, unde aproape nimeni nu trece.

Rezultatul global e influențat de ce fel de studenți au dat examen la fiecare disciplină, nu doar de disciplină.

↳ paradoxul lui Simpson: a concluzie valabilă în fiecare grup separat se inversează când punem grupurile împreună

B. $P(P|B, P_1) = 0.95 > 0.90 = P(P|A, P_1)$

↳ dacă studentul e din Programul 1, are șanse mai mari să promoveze la B decât A

$P(P|B, P_2) = 0.20 > 0.10 = P(P|A, P_2)$

$\Rightarrow$ Pe fiecare program B este mai bună

$P(P|A) = 0.82 > 0.35 = P(P|B)$

↳ dacă nu ținem cont de program, un student de la A pare să aibă șanse mai mari

$\Rightarrow$ Global, A e mai bună